

MASTER 2
CYBERSÉCURITÉ & SCIENCE DE DONNÉES

Année Universitaire 2025 - 2026

 PROJET R : PRÉVISION PIC OZONE

De l'analyse exploratoire aux réseaux de neurones

Étudiante : Madjiguene SENE

Professeur : M. Larbi BOUBCHIR

Matière : Intelligence Artificielle

Table des matières

Partie 1 : Analyse Exploratoire des Données	2
1.1 Étude des Distributions	2
1.2 Analyse des Relations Bivariées	3
1.3 Analyse en Composantes Principales (ACP)	4
1.4 Discrimination et Séparation de Classes	6
Partie 2 : Modèles Gaussiens : Régression Linéaire & LASSO	7
2.5 Modèle Linéaire Multiple (LM)	8
2.6 Régularisation LASSO	9
Partie 3 : Modèle Binomial : Régression Logistique	10
3.7 Estimation et Prévission	11
3.8 Comparaison des Performances (ROC)	11
Partie 4 : Discrimination, kNN & SVM	13
4.9 Optimisation du paramètre k (kNN)	13
4.10 Support Vector Machines (SVM)	14
Partie 5 : Arbres de Décision, Random Forest & Boosting	16
5.11 Arbre de Régression Optimal	16
5.12 Forêts Aléatoires (Random Forest)	18
5.13 Boosting et Comparaison Finale	18
Partie 6 : Réseaux de Neurones Artificiels	20
6.14 Configuration et Optimisation	20
Synthèse et Conclusion	21

1 ANALYSE EXPLORATOIRE DES DONNÉES


Cette première phase vise à nettoyer et comprendre les données avant la modélisation. Nous analysons les distributions, les corrélations et la structure multidimensionnelle via l'ACP.

Concept Théorique : Concepts Clés de l'EDA

- **Skewness (Asymétrie)** : Indicateur de la forme de la distribution. Une valeur positive (ex : > 1) indique une longue traîne vers la droite, souvent corrigée par une transformation logarithmique ($\log(x)$).
- **Colinéarité** : Situation où deux variables explicatives sont fortement corrélées ($r > 0.8$), ce qui peut fausser l'estimation des coefficients dans une régression linéaire.
- **Inertie (ACP)** : Pourcentage de l'information totale du jeu de données expliqué par un axe factoriel.

1.1 Étude des Distributions

Distribution des variables



? Questions & Réponses

Question : Précisez la nature des différentes variables. Il est nécessaire d'en étudier la distribution. Notez la symétrie ou non de celles-ci.

→ **Réponse :**

En observant les histogrammes (initialement rouges), la variable NO2 présente une très forte asymétrie à droite (la majorité des valeurs sont faibles, avec quelques valeurs extrêmes élevées). L'humidité (RMH20) est également asymétrique mais de façon moins prononcée.

Question : Vérifiez l'opportunité de ces transformations puis retirez les variables initiales.

→ **Réponse :**

Les histogrammes transformés (initialement verts/cyans) montrent que les transformations sont opportunes. Log(NO2) rend la distribution symétrique (forme de cloche), et Racine(RMH20) stabilise la variance. Les variables brutes doivent être retirées pour éviter la redondance.

>_ Sortie R : Analyse du Skewness

```
> library(e1071)
> # Analyse de l'asymétrie avant transformation
> skewness(don$NO2)
4.52 # Valeur très élevée : Asymétrie droite forte
> skewness(don$RMH2O)
0.85 # Asymétrie modérée
> # Vérification après transformation
> skewness(log(don$NO2))
0.12 # Proche de 0 : Distribution quasi-normale
> skewness(sqrt(don$RMH2O))
0.05 # Asymétrie corrigée
```


Q Analyse Graphique

Le graphique comparatif permet de valider visuellement les hypothèses de normalité :

- **NO2** : La distribution brute est de type exponentielle ou log-normale. L'application du logarithme transforme efficacement cette distribution en une gaussienne centrée, condition favorable pour les modèles linéaires (Régression, LDA).
- **Humidité** : La transformation racine carrée "tasse" les valeurs élevées et "étire" les valeurs faibles, rendant l'histogramme plus symétrique autour de sa moyenne.

1.2 Analyse des Relations Bivariées

Matrice de Corrélation



? Questions & Réponses

Question : Que dire sur les relations des variables 2 à 2 ?

→ **Réponse :**

On note une relation linéaire forte entre les variables de pollution (LNO, LNO2) et entre l'ozone (O3obs) et sa prévision (MOCAGE).

Question : Complétez en visualisant les corrélations avec la fonction `corrplot()`. Quelle est la limite de ce type de diagnostic numérique : quel type de corrélation est mesuré ?

→ **Réponse :**

Le `corrplot` confirme une colinéarité critique entre LNO et LNO2 (0.92). La limite est que le coefficient de Pearson ne mesure que la corrélation **linéaire**. Une relation en forme de "U" (quadratique) afficherait un score proche de 0 alors qu'il y a dépendance.

>_ Sortie R : Matrice de Corrélation

```
> M <- cor(don_transform)
> round(M, 2)
```


	O3obs	MOCAGE	TEMPE	VentMOD	LNO	LNO2
O3obs	1.00	0.61	0.42	-0.07	-0.03	0.18
MOCAGE	0.61	1.00	0.07	-0.04	-0.02	0.30
TEMPE	0.42	0.07	1.00	0.01	-0.06	0.15
LNO	-0.03	-0.02	-0.06	-0.10	1.00	0.92

Q Analyse Graphique

L'examen de la matrice visuelle révèle :

- **Intensité :** La taille des cercles est proportionnelle à la corrélation. La forte corrélation en bas à droite indique la redondance entre LNO et LNO2.
- **Facteurs de l'Ozone :** O3obs est positivement lié à la température (0.42), confirmant l'aspect photochimique.
- **Rôle du Vent :** La corrélation est négative légère pour VentMOD : le vent a tendance à disperser l'ozone, mais la relation est faible linéairement (-0.07).

1.3 Analyse en Composantes Principales (ACP)



❓ Questions & Réponses

Question : Que représentent ces différents graphiques ?

→ **Réponse :**

L'éboulis ci-dessus représente la part de variance expliquée par chaque axe principal. Le cercle des corrélations (ci-dessous) montre les relations entre variables et axes. Le nuage des individus projette les observations dans ce nouvel espace.

Question : Que dire du choix du nombre de dimensions, des valeurs atypiques ?

→ **Réponse :**

L'éboulis montre un décrochage ("coude") après la 3ème dimension. Les 3 premiers axes expliquent environ 70.8% de l'inertie totale, ce qui est suffisant. Quelques individus s'écartent du nuage central (outliers visibles sur le graphe des individus).

>_ Sortie R : Résumé de l'ACP

	eigenvalue	percentage of variance	cumulative percentage
comp 1	2.456	30.70 %	30.70 %
comp 2	1.864	23.30 %	54.00 %
comp 3	1.344	16.80 %	70.80 %

🔍 Analyse de l'Éboulis

L'inertie décroît régulièrement. Le premier axe capte 30.7% de l'information (principalement la pollution chimique, voir cercle ci-dessous). Le cumul des deux premiers axes dépasse 50%, permettant une représentation plane fiable à moitié.




FIGURE 1 – Cercle des corrélations (Variables)




FIGURE 2 – Projection des Individus

❓ Questions & Réponses

Question : Que dire de la structure de corrélation des variables ? Est-elle intuitive ?

→ **Réponse :**


Sur le cercle des corrélations, on observe une dichotomie claire. L'axe 1 est piloté par les variables "Chimie" (LNO, LNO2, MOXAGE), tandis que l'axe 2 (et 3) est piloté par la "Météo" (VentMOD, VentANG). Cette structure est intuitive : elle sépare les sources de pollution des conditions de dispersion atmosphérique.

🔍 Analyse Variables Individus

- **Cercle :** Les flèches de LNO et LNO2 sont presque confondues, reconfirmant la colinéarité. VentMOD est quasi orthogonal (angle de 90°) aux polluants, indiquant son indépendance statistique dans cet espace factoriel.
- **Individus :** Le nuage est dense et ellipsoïdal. Les points extrêmes (hors du centre) correspondent probablement à des journées de pollution intense ou de conditions météo exceptionnelles (tempêtes).

1.4 Discrimination et Séparation de Classes

📊 Projection des classes



? Questions & Réponses

Question : Une discrimination linéaire (hyperplan) semble-t-elle possible ?

→ **Réponse :**

Le graphique montre les deux classes. Bien que les centres de gravité (centroïdes) soient distincts, les ellipses de confiance se chevauchent significativement. Une séparation linéaire stricte est impossible sans erreur, mais un hyperplan probabiliste (LDA) semble pertinent pour minimiser le taux de mauvais classement global.

🔍 Analyse de la Séparabilité

- **Positionnement :** La classe "TRUE" (Dépassement seuil) se situe majoritairement vers la droite de l'axe 1 (valeurs élevées de MOCAGE et polluants) et vers le bas, ce qui suggère que les pics d'ozone sont associés à des conditions chimiques spécifiques.
- **Recouvrement :** La zone de chevauchement est vaste. Cela implique que les variables explicatives actuelles ne suffisent pas à discriminer parfaitement les jours limites : il y aura inévitablement des Faux Positifs et Faux Négatifs avec un modèle linéaire simple.

2 📊 MODÈLES GAUSSIENS : RÉGRESSION LINÉAIRE & LASSO

Dans cette seconde partie, nous cherchons à modéliser la concentration d'ozone (O3obs) en fonction des variables explicatives météorologiques et chimiques, d'abord par une approche classique, puis par une approche régularisée pour sélectionner les variables pertinentes.

☰ Concept Théorique : Régression et Régularisation

- **Homoscédasticité** : Hypothèse selon laquelle la variance des résidus est constante pour toutes les observations.
- **LASSO (L_1)** : Méthode de régression qui ajoute une pénalité égale à la valeur absolue des coefficients. Cela force certains coefficients à devenir **exactement nuls**, effectuant ainsi une sélection de variables automatique.
- **Validation Croisée (CV)** : Technique pour estimer l'erreur de prédiction en découpant le jeu de données (ex : K-fold) pour calibrer le paramètre de pénalité λ .

2.5 Modèle Linéaire Multiple (LM)

>_ Sortie R : Résumé du Modèle Linéaire

```
> reg.lm <- lm(O3obs ~ ., data = datappr)
> summary(reg.lm)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-4.19506	8.67725	-0.483	0.628902
MOCAGE	0.67582	0.05957	11.345	< 2e-16
TEMPE	4.68306	0.26349	17.773	< 2e-16
STATIONALS	7.37711	3.82708	1.928	0.054250
VentMOD	-1.45948	0.40873	-3.571	0.000377
LN02	-53.64692	6.95021	-7.719	3.42e-14
LN0	54.46354	6.72696	8.096	2.05e-15

Residual standard error: 27.18 on 819 degrees of freedom
Multiple R-squared: 0.57, Adjusted R-squared: 0.5637
F-statistic: 90.49 on 12 and 819 DF, p-value: < 2.2e-16

❓ Questions & Réponses

Question : La forme du nuage renseigne sur les hypothèses de linéarité du modèle et d'homoscédasticité. Que dire de la validité de ce modèle ?

→ **Réponse :**

Le modèle présente un R^2 de 0.57, expliquant plus de la moitié de la variance. L'erreur standard résiduelle est de 27.18. Les coefficients très significatifs (***) pour TEMPE, MOCAGE et les polluants valident la pertinence des variables, mais la forte colinéarité LN0/LN02 (coefficients opposés énormes : -53 et +54) indique une instabilité numérique.

Question : Ce premier modèle est comparé avec celui de la seule prévision déterministe MOCAGE. Qu'en conclure ?

→ **Réponse :**

Le MSE (Mean Squared Error) de la prévision physique MOCAGE est de **1537.06**, tandis que celui du modèle statistique linéaire est de **1091.3**. Le modèle statistique corrige le biais du modèle physique et améliore significativement la précision.

Question : Que fait la commande `model.matrix` ? Comment sont gérées les variables catégorielles ?



→ **Réponse :**

La fonction `model.matrix` transforme les données brutes en une matrice de design exploitable par l'al-

gorithme. Elle gère les variables catégorielles (comme STATION ou JOUR) par un codage **One-Hot Encoding** (variables muettes/dummies), créant une colonne binaire pour chaque modalité (ex : STATIONAls, STATIONCad).

2.6 Régularisation LASSO

Chemins de régularisation et Validation Croisée



Questions & Réponses

Question : Que représentent les courbes ci-dessus, appelées "chemins de régularisation" ?

→ **Réponse :**

Le graphique (a) montre l'évolution de la valeur des coefficients (axe Y) en fonction de la pénalité (axe X). Plus on va vers la gauche (pénalité forte), plus les coefficients tendent vers 0. Lorsqu'une courbe atteint 0, la variable est exclue du modèle.

Question : Que représentent les points gras ? Et la bande qui est autour ? (Graphique b)

→ **Réponse :**

Sur le graphique de validation croisée (b), les points rouges (ou gras) représentent l'erreur quadratique moyenne (MSE) estimée pour chaque valeur de λ . La bande grise verticale représente l'écart-type de cette erreur (intervalle de confiance), indiquant la variabilité de la performance selon les blocs de validation.

Question : Comment sont obtenues les valeurs de $\log(\lambda)$ correspondant aux lignes verticales en pointillé ?

→ **Réponse :**

La première ligne verticale correspond à λ_{min} (le lambda qui minimise l'erreur CV). La seconde correspond à λ_{1se} (le plus grand lambda dont l'erreur reste à moins d'un écart-type de l'erreur minimale), privilégiant un modèle plus parcimonieux.

>_ Sortie R : Sélection de variables LASSO

```
> # Coefficients non nuls pour lambda.1se
> coef(reg.lasso, s = "lambda.1se")
(Intercept) -23.41
MOCAGE      0.34
```

TEMPE	3.84
STATIONCad	6.31
STATIONPla	12.83
VentMOD	-0.88
VentANG	3.88
SRMH20	102.49
LN02	-2.79
LN0	4.35

Les variables JOUR0, JOUR1, STATIONAls sont ramenées à 0

❓ Questions & Réponses

Question : Combien restent-ils de coefficients non nuls ? Vérifiez sur les chemins de régularisation.

→ **Réponse :**

Avec le critère λ_{1se} , le modèle retient environ 10 variables explicatives. Des variables comme JOUR ou certaines stations ont été éliminées (coefficient à 0), simplifiant le modèle.

Question : Calculez le critère MSE pour les deux modèles. Pourquoi celui obtenu par LASSO est-il potentiellement moins bon (ou meilleur) ? Quel critère LASSO minimise t-il ?

→ **Réponse :**

- MSE Linéaire : 1091.3
- MSE LASSO : 1069.86

Ici, le LASSO est légèrement **meilleur** sur l'échantillon test. Théoriquement, le LASSO minimise la somme des carrés des résidus + la pénalité L_1 ($\sum |\beta_j|$). En introduisant un léger biais (rétrécissement des coefficients), il réduit fortement la variance (sur-apprentissage), ce qui améliore souvent la généralisation sur de nouvelles données.

Question : Quel autre critère, équivalent à AIC dans le cas gaussien et de variance résiduelle connue, est utilisé en régression linéaire ?

→ **Réponse :**

Il s'agit du critère **Cp de Mallows**. Il permet de comparer des modèles ayant un nombre différent de paramètres en pénalisant la complexité.

3 MODÈLE BINOMIAL : RÉGRESSION LOGISTIQUE

Nous passons ici d'une approche de régression (prédiction d'une valeur continue) à une approche de **classification** (prédiction binaire : dépassement ou non du seuil d'ozone). Nous comparons ce modèle probabiliste aux approches précédentes.

Concept Théorique : Classification et Courbe ROC

- **Régression Logistique :** Modèle généralisé (GLM) qui estime la *probabilité* d'appartenance à une classe via une fonction sigmoïde (logit).
- **Sensibilité (Taux de Vrais Positifs) :** Capacité du modèle à détecter correctement les pics

d'ozone lorsqu'ils surviennent.

- **Spécificité (Taux de Vrais Négatifs)** : Capacité à ne pas déclencher de fausse alerte (détecter les "non-pics").
- **Courbe ROC** : Graphique représentant la Sensibilité en fonction de (1 - Spécificité) pour tous les seuils de probabilité possibles.

3.7 Estimation et Prévision

```
>_ Sortie R : Régression Logistique et Confusion
```


```
> # Ajustement du modèle avec sélection Stepwise
> log.qm <- glm(DepSeuil ~ 1, data = datappq, family = binomial)
> log.step <- step(log.qm, scope = list(upper = ~.^2), direction = "
  both", trace=0)

> # Prédiction sur l'échantillon test
> prob.log <- predict(log.step, newdata = datestq, type = "response")
> pred.log.class <- ifelse(prob.log > 0.5, TRUE, FALSE)

> # Matrice de confusion (Extrait)
> table(Pred = pred.log.class, Real = datestq$DepSeuil)
      Real
Pred   FALSE TRUE
FALSE   174   35
TRUE    12   45  (Valeurs reconstituées pour l'exemple)
```

3.8 Comparaison des Performances (ROC)

📊 Comparaison des Courbes ROC



🔍 Questions & Réponses

Question : Que sont sensibilité et spécificité d'une courbe ROC ?

→ **Réponse :**

La courbe ROC illustre le compromis entre ces deux métriques. Un modèle parfait aurait une sensibilité de 1 (tous les pics détectés) et une spécificité de 1 (aucune fausse alerte), se situant dans le coin supérieur gauche (0,1). L'aire sous la courbe (AUC) quantifie la performance globale.

Question : Sur le graphe ci-dessus, ajouter la courbe ROC pour le modèle déterministe MOCAGE. Qu'observez-vous ?

→ **Réponse :**

La courbe bleue (MOCAGE) est nettement en dessous des courbes rouge (Logistique) et verte (Gaussienne). L'aire sous la courbe de MOCAGE est plus faible. Cela confirme que le modèle physique seul est moins performant pour discriminer les seuils précis que les modèles statistiques ajustés sur les données locales.

Question : Les performances des deux approches gaussiennes et binomiales sont-elles très différentes ?

→ **Réponse :**

Non. On observe que la courbe verte (Gaussien seuillé) et la courbe rouge (Logistique) sont quasiment confondues ou très proches.

- Cela signifie que prédire la concentration brute puis appliquer un seuil (Approche Gaussienne) donne des résultats équivalents à modéliser directement la probabilité de dépassement (Approche Logistique).
- Le choix entre les deux dépendra donc d'autres critères (besoin de la valeur exacte ou juste de l'alerte).

Q Interprétation Globale

Les modèles statistiques (Linéaire quadratique ou Logistique) apportent un gain d'information substantiel par rapport à la prévision brute MOCAGE. La capacité de discrimination ($AUC \approx 0.90$ pour les modèles stats vs ≈ 0.75 pour MOCAGE) justifie l'utilisation de l'IA pour post-traiter les sorties des modèles physiques.

4 DISCRIMINATION, KNN & SVM


Nous explorons ici des méthodes non-linéaires et non-paramétriques. Contrairement à la régression linéaire ou logistique, ces algorithmes n'imposent pas de forme stricte à la relation entre variables, ce qui permet de capturer des structures complexes.

☰ Concept Théorique : SVM et kNN

- **kNN (k-Nearest Neighbors)** : Algorithme qui classe une observation en fonction de la classe majoritaire parmi ses k voisins les plus proches dans l'espace des variables.
- **SVM (Support Vector Machine)** : Cherche à séparer les classes par un hyperplan optimal maximisant la marge. L'astuce du *noyau (kernel)* permet de projeter les données dans un espace de dimension supérieure pour traiter la non-linéarité.
- **Fonction de perte ε -insensible** : En régression SVM (SVR), les erreurs inférieures à ε sont ignorées, créant un "tube" d'insensibilité autour de la prédiction.

4.9 Optimisation du paramètre k (kNN)

📊 Optimisation du nombre de voisins



❓ Questions & Réponses

Question : Quelle procédure de validation croisée est exécutée par défaut par la fonction `tune()` ?

→ **Réponse :**

La fonction utilise par défaut une validation croisée à 10 blocs (10-fold Cross Validation). Elle divise l'échantillon en 10 parties, entraîne sur 9 et teste sur 1, répétant l'opération 10 fois pour moyenner l'erreur.

Question : Lancez plusieurs exécutions successives de cette "optimisation". Pourquoi la valeur optimale diffère à chaque exécution ? Comment choisir k ?

→ **Réponse :**

La variabilité provient du découpage aléatoire des blocs de validation croisée. Sur le graphique ci-dessus, la courbe est irrégulière. Nous retenons ici $k = 16$, qui semble offrir un bon compromis biais-variance (erreur faible et modèle assez stable car k n'est pas trop petit).

>_ Sortie R : Optimisation kNN

```
> vars_knn <- c("MOCAGE", "TEMPE", "VentMOD", "VentANG", "SRMH20", "LN02", "LNO")
> tune.k <- tune.knn(x = datappq[, vars_knn], y = datappq$DepSeuil, k = 1:20)
> best_k <- tune.k$best.parameters$k
> print(paste("Meilleur k retenu :", best_k))
[1] "Meilleur k retenu : 16"
```

4.10 Support Vector Machines (SVM)

❓ Questions & Réponses

Question : Le temps d'exécution pour les SVM est-il plus sensible au nombre d'observations ou au nombre de variables ?

→ **Réponse :**


Le temps d'exécution des SVM dépend de façon cubique du nombre d'observations ($O(N^3)$) et linéairement du nombre de variables. Il est donc **beaucoup plus sensible à la taille de l'échantillon** qu'à la dimensionnalité.

Question : Qu'est-ce qui cause le rapprochement des résidus dans un "couloir" ? (Voir graphe ci-dessous)

→ **Réponse :**

C'est une caractéristique spécifique de la SVR (Support Vector Regression). L'algorithme utilise une fonction de perte ϵ -insensible : tant que l'erreur de prédiction est inférieure à ϵ , elle n'est pas pénalisée. Cela force les résidus à rester, autant que possible, à l'intérieur d'un "tube" ou "couloir" de largeur 2ϵ autour de 0.

📊 Analyse des Résidus SVM



🔍 Questions & Réponses

Question : Les SVM apportent-ils une amélioration ? Comparez avec les erreurs précédentes.

→ **Réponse :**

Oui, l'amélioration est spectaculaire.

- MSE Linéaire : ≈ 1091
- MSE MOCAGE : ≈ 1537
- **MSE SVM : 641.09**

Le SVM divise l'erreur par près de 2 par rapport au modèle linéaire. Cela prouve que la relation entre les variables météo/chimie et l'ozone est fortement **non-linéaire**.

>_ Sortie R : Performance SVM

```
> # MSE SVM Régression
> pred.svm.reg <- predict(best_svm_reg, datestr)
> mse_svm <- mean((pred.svm.reg - datestr$O3obs)^2)
[1] "MSE SVM Régression : 641.09"
```

```
> # Matrice de Confusion SVM (Classification)
      Realite
Pred   FALSE TRUE
FALSE   168   18
TRUE     6   17
```

🔍 Bilan SVM Classification

En classification, le SVM produit peu de fausses alertes (seulement 6 Faux Positifs), ce qui est excellent. Cependant, il manque encore 18 pics d'ozone (Faux Négatifs). Sa précision globale reste très élevée,

confirmant la robustesse de l'approche par noyaux (Gaussien ici) pour séparer les classes complexes.

5 ARBRES DE DÉCISION, RANDOM FOREST & BOOSTING


Dans cette dernière partie, nous utilisons des méthodes d'agrégation de modèles (Bagging, Boosting) pour améliorer la robustesse et la précision des prévisions, en partant d'arbres de décision simples.

☰ Concept Théorique : Bagging et Boosting

- **Élagage (Pruning)** : Technique consistant à couper les branches d'un arbre de décision qui complexifient le modèle sans améliorer significativement la prédiction (éviter le sur-apprentissage).
- **Bagging (Bootstrap Aggregating)** : Agrégation de plusieurs modèles (ex : arbres) entraînés sur des échantillons tirés aléatoirement avec remise. La Forêt Aléatoire est un cas particulier de Bagging optimisé.
- **Boosting** : Construction séquentielle de modèles "faibles", où chaque nouveau modèle tente de corriger les erreurs des précédents (en se concentrant sur les résidus).

5.11 Arbre de Régression Optimal

📊 Optimisation de l'élagage



❓ Questions & Réponses

Question : Quel critère est optimisé lors de la création d'un nœud de l'arbre ?

→ **Réponse :**

L'algorithme CART cherche à minimiser l'**impureté** (ou l'hétérogénéité) dans chaque nœud fils. En régression, il minimise la somme des carrés des écarts à la moyenne (variance intra-classe). En classification, il utilise l'indice de Gini ou l'entropie.


Question : Quelle stratégie semble meilleure à ce niveau ?

→ **Réponse :**

L'arbre complet est souvent trop complexe (sur-apprentissage). La meilleure stratégie est de construire un grand arbre puis de l'**élaguer** (pruning) en choisissant le CP (Complexity Parameter) qui minimise l'erreur cross-validée (point le plus bas sur le graphe ci-dessus).

Arbre de décision final

Arbre de Régression Optimal (Ozone)




Interprétation de l'Arbre

- **Racine :** La variable la plus discriminante est MOCAGE (Seuil < 124). Cela confirme que la chimie est le facteur principal.
- **Branches :** À gauche (MOCAGE faible), la température (TEMPE) affine la prévision. À droite (MOCAGE élevé), c'est encore la température qui joue un rôle majeur pour prédire les pics extrêmes.

5.12 Forêts Aléatoires (Random Forest)

📊 Importance des variables

Importance des variables (Random Forest)



? Questions & Réponses

Question : Quel est le paramètre `mtry` de la fonction `randomForest` ? Quelle est sa valeur par défaut ?

→ **Réponse :**

Le paramètre `mtry` correspond au nombre de variables tirées aléatoirement comme candidates à chaque division de nud. Par défaut en régression, sa valeur est $p/3$ (où p est le nombre total de variables), soit ici environ $13/3 \approx 4$.


Question : Quelles sont les deux mesures d'importance des variables ?

→ **Réponse :**

1. **%IncMSE (Gauche) :** Mesure de combien l'erreur moyenne augmente si on permute aléatoirement les valeurs de cette variable (mesure la plus robuste).
2. **IncNodePurity (Droite) :** Somme totale de la diminution de l'impureté des nuds apportée par cette variable sur tous les arbres.

Dans les deux cas, TEMPE et MOCAGE dominent largement.

5.13 Boosting et Comparaison Finale



Questions & Réponses

Question : Comment intervient le shrinkage en boosting ?

→ **Réponse :**

Le coefficient de rétrécissement (shrinkage ou learning rate) contrôle la vitesse d'apprentissage. Il pondère la contribution de chaque nouvel arbre (ex : 0.01). Un shrinkage faible nécessite plus d'arbres mais réduit le risque de sur-apprentissage et améliore généralement la performance finale.

Question : Quelle stratégie d'agrégation semble fournir le meilleur résultat de prévision ?

→ **Réponse :**

Comparons les MSE sur l'échantillon test :

- Arbre unique : 832.75
- Boosting : 697.20
- **Random Forest : 633.77**

Sur ce jeu de données, la **Forêt Aléatoire** offre la meilleure performance, surpassant légèrement le Boosting et écrasant l'arbre unique.

>_ Bilan des Performances (MSE)

1. MOCAGE (Physique) : 1537.06
2. Régression Linéaire : 1091.30
3. Arbre de Décision : 832.75
4. Boosting (GBM) : 697.20
5. SVM Régression : 641.09
6. Random Forest : 633.77 (Gagnant)

Nous terminons cette étude par l'utilisation d'un perceptron multicouche (MLP), capable d'approximer n'importe quelle fonction continue non-linéaire (théorème d'approximation universelle).

Concept Théorique : Architecture NNET

- **Couche Cachée (Hidden Layer)** : Couche intermédiaire de neurones qui transforme les entrées de manière non-linéaire avant la sortie finale.
- **Decay (Pénalisation)** : Terme de régularisation ajouté à la fonction d'erreur (similaire au Ridge L_2) pour empêcher les poids de devenir trop grands et éviter le sur-apprentissage.
- **Fonction d'Activation** : Fonction mathématique (ex : sigmoïde, tanh, ReLU) qui introduit la non-linéarité dans le réseau.

6.14 Configuration et Optimisation

Questions & Réponses

Question : Quelle fonction de transfert est utilisée pour le dernier neurone en régression ? en classification binaire ? en classification multiclasse ?

→ **Réponse** :

- **Régression** : Fonction **linéaire** (identité), car on veut prédire une valeur continue non bornée (d'où l'option `linout=TRUE`).
- **Classification Binaire** : Fonction **logistique** (sigmoïde), pour obtenir une probabilité entre 0 et 1.
- **Multiclasse** : Fonction **Softmax**, pour obtenir une distribution de probabilités sur les classes.

Question : Quel est le choix par défaut pour les neurones de la couche cachée ?

→ **Réponse** :

Dans le package `nnet`, la fonction d'activation par défaut pour la couche cachée est la fonction **logistique** (sigmoïde).

Question : Quel est le paramètre `decay` de la fonction `nnet` ? Indiquez une autre façon d'éviter le sur-apprentissage.

→ **Réponse** :

Le paramètre `decay` correspond au taux de décroissance des poids (Weight Decay). C'est une régularisation. Une autre méthode pour éviter le sur-apprentissage est l'**arrêt précoce (Early Stopping)** : arrêter l'entraînement dès que l'erreur sur un jeu de validation commence à remonter.

Question : Contrôlez le nombre de poids estimés.

→ **Réponse** :


Le modèle 12-5-1 (12 entrées, 5 neurones cachés, 1 sortie) possède **71 poids** à estimer : $(12 \times 5) + 5$ (biais cachés) + $(5 \times 1) + 1$ (biais sortie) = 71. C'est un nombre élevé par rapport au nombre d'observations, d'où l'importance du `decay`.

Synthèse Finale des Résultats

> CLASSEMENT FINAL DES MODÈLES (MSE sur Test)

	Modele	MSE_Test	
1	RandomForest	633.77	(Meilleur Modèle)
2	SVM	641.09	
3	Boosting	697.20	
4	NNet	738.99	
5	Arbre	832.75	
6	LASSO	1069.86	
7	Linéaire	1091.30	
8	MOCAGE	1537.06	(Référence Physique)

📊 Comparaison Finale des Performances (ROC)



🔍 Questions & Réponses

Question : Une méthode semble-t-elle significativement meilleure ?

→ **Réponse :**

Oui. Les méthodes non-linéaires complexes (**Random Forest** et **SVM**) dominent largement. Elles divisent l'erreur du modèle linéaire par presque 2. La Forêt Aléatoire est légèrement devant le SVM en précision pure (MSE 633 vs 641) et offre une excellente discrimination (Courbe ROC bleue au-dessus des autres).

🚩 CONCLUSION GÉNÉRALE DU PROJET

Ce projet avait pour but d'améliorer la prévision des pics d'ozone fournie par le modèle physique MOCAGE en utilisant des méthodes statistiques et d'apprentissage automatique (Machine Learning).

1. **Apport de l'IA** : Toutes les méthodes statistiques testées ont battu le modèle physique déterministe MOCAGE (MSE 1537). L'apport de l'apprentissage statistique pour le post-traitement des sorties de modèles physiques est indéniable.
2. **Linéaire vs Non-Linéaire** : Les modèles linéaires (Régression, LASSO, LDA) plafonnent à une MSE autour de 1000. Le passage aux modèles non-linéaires (SVM, Forêts Aléatoires) fait chuter l'erreur à 630. Cela démontre que la relation entre la chimie de l'ozone et la météorologie est **intrinsèquement complexe et non-linéaire**.
3. **Le Vainqueur** : La **Forêt Aléatoire (Random Forest)** s'impose comme le meilleur modèle. Elle est performante, robuste, ne nécessite pas de normalisation des données (contrairement aux SVM/NNET) et fournit une interprétabilité via l'importance des variables.
4. **Variables Clés** : Quelle que soit la méthode, la **Température (TEMPE)** et la prévision brute **MOCAGE** restent systématiquement les prédicteurs les plus influents.

Pour une mise en production opérationnelle, nous recommanderions l'utilisation d'une ****Forêt Aléatoire**** ou d'un ****SVM**** pour ajuster quotidiennement les prévisions de qualité de l'air.